

求职意向与个人简介

- 求职意向 AI infra 与 芯片架构工程师 (软件研发类) · 工作地上海 · 2026 年 11 月获硕士学位 (2027 届) · 2026 年 9 月起可入职。
- 爱丁堡大学 ICSA 研究型硕士, 方向为 **AI 算力基础设施与性能工程**: GPU 算力共享与抢占、算力划分与干扰刻画、分布式训练性能建模, 成果发表于 **MobiCom**、**EdgeSys** (最佳论文)、**SEC**。工程侧以 **C/C++** 写事件驱动分布式后端与容错逻辑, 并具备 **Triton** 算子开发、**CUDA Green Context** 算力分区、**Verilog/FPGA** 处理器实现与 **Linux** 内核构建经验。

教育背景

- 爱丁堡大学 (The University of Edinburgh) 英国爱丁堡
计算机科学研究型硕士, *ICSA*, 导师 *Mahesh K. Marina* 教授 2025.09 – 2026.11 (预计)
 - 硕士论文 *Flux-DT*: 面向可回收算力的弹性、抗抢占有状态运行时。
- 爱丁堡大学 (The University of Edinburgh) 英国爱丁堡
计算机科学学士, 一等荣誉学位 (*First Class Honours*, 英国最高等级) 2021.09 – 2025.05
 - 相关课程: 计算机体系结构与设计 (A)、机器学习系统 (A)、操作系统、计算机系统。

专业技能

- 编程语言 C / C++ (主力, 事件驱动分布式后端)、Python、Verilog、Bash、Java。
- 体系结构与硬件 RISC-V 处理器 RTL 实现与微架构优化、流水线冒险与前递、Cache 与存储层次定量分析 (CPI / 带宽)、FPGA 开发与上板验证 (Vivado、PYNQ-Z2)、CUDA Green Context 与 SM 算力分区。
- AI 系统 PyTorch、Triton GPU 算子开发与调优、分布式训练、GPU 集群调度与抢占容忍、加速器干扰刻画、性能建模与 profiling。
- 系统与工具 Linux 内核构建与内核模块、KVM 虚拟化、LLVM 编译优化与自动量化、Protobuf 与自研 RPC、epoll 事件驱动网络编程、Docker、Kubernetes、Azure / GCP、Git。

科研与项目经历

- **Weaver: Foundation Model Training over Shared AI Compute Infrastructure** 论文在投
研究助理——算力借用控制器评测、GPU 剖析与大规模训练实验 2024 – 2026
 - 算力借用与干扰刻画: 评测决定 AI 训练负载可从延迟敏感租户处借用多少加速器算力的控制器 (近实时资源分配问题), 多站点测试床上借用至多 **83%** 空闲算力且不损害同驻租户性能; 以 GPU profiling 刻画两类负载间的资源干扰, 并执行评测所需的大规模分布式训练。
- **Morphling: Emulator for Distributed Machine Learning at the Edge** EdgeSys 2026, 最佳论文奖
研究助理——C++ 后端、故障容错与 GPU 算力划分 2025.10 – 2026.03
 - C++ 后端与容错: 以 epoll 事件循环与 Protobuf 实现代理服务端 / 客户端与设备追踪模块 (约 50 次提交集中于 *csrc/backend*), 支撑单台 GPU 服务器模拟至多 1,800 台异构设备; 实现故障检测与目标重选、分区重排、运行期动态增删设备, 修复故障引发的通信死锁。
 - GPU 算力划分: 基于 CUDA Green Context 的 per-GEMM SM 分区, 经 autograd hook 按执行 trace 驱动切换, 实现细粒度 GPU 算力隔离与共享。
- **GPU 算子开发与调优 (Machine Learning Systems 课程项目, 成绩 A)** 爱丁堡大学, 2024
用 Triton 手写 L2、余弦、点积、曼哈顿四类距离算子, 并实现 KNN、K-Means 与近似最近邻检索; 按 BLOCK_SIZE 分块切分、掩码处理边界、合并访存降低带宽压力, 替换框架层通用实现。
- **RISC-V 处理器设计与 FPGA 实现 (Computer Architecture and Design 课程项目, 成绩 A)** 爱丁堡大学, 2023
用 Verilog 实现算术逻辑单元、寄存器堆等部件并集成为可运行的 RISC-V 处理器, 经 Vivado 综合实现后下载至 **PYNQ-Z2** 开发板实测验证; 自行设计微架构增强方案并按定量方法评估 CPI 与访存带宽收益。
- **EmuRAN: Scalable and Cost-Effective Cloud-based RAN Emulation System** MobiCom 2026, 有条件录用
研究助理——云上部署与端到端评测 2024 – 2026
 - 内核、虚拟化与规模评测: 编译部署自定义 Linux 内核模块与改版 KVM 模块以支持时间膨胀虚拟机, 自动化完成实例创建、网状路由与 Kubernetes 组建; 在公有云 **130 实例**、**6,400 CPU 核**上模拟超 **10,000** 台设备, 规模较既有方案高两个数量级, 并设计执行保真度与可扩展性评测。

论文发表

- *EmuRAN* Scalable and Cost-Effective Cloud-based RAN Emulation System ——**MobiCom 2026** (有条件录用), 第三作者。
- *Morphling* Emulator for Distributed Machine Learning at the Edge ——**EdgeSys 2026**, 第二作者, 最佳论文奖。
- *Wasp* Foundation Model Training System for the Edge ——**SEC 2026**, 第二作者。
- *CoSenseAQ* Compiler Optimizations using Sensor Technical Specifications with Automatic Quantization ——论文在投, 第一作者。
- *Weaver* Foundation Model Training over AI-RAN Compute Infrastructure ——论文在投, 合作作者。

实习、荣誉与其他

- 实习 森科技有限公司 (苏州) 后端开发实习生, 2023.06–2023.09: 交付线上后端接口, 主导优衣库配送平台由 JFinal 迁移至 Spring Boot (Java、MySQL、Redis、Kafka)。
- 荣誉与其他 EdgeSys 2026 最佳论文奖; 本科一等荣誉学位; 中文母语、英语流利 (雅思 7.0、GRE 336); EuroSys 2026 学生志愿者。