

求职意向与个人简介

- **求职意向** AI infra 与芯片架构工程师 (软件研发类) · 工作地上海 · 2026 年 11 月获硕士学位 (2027 届) · 2026 年 9 月起可实习或全职入职。
- 爱丁堡大学计算系统架构研究所 (ICSA) 研究型硕士, 导师 Mahesh K. Marina 教授, 研究方向为 **AI 算力基础设施、加速器调度与性能工程**: GPU 算力共享与抢占、算力划分与干扰刻画、分布式训练系统的性能建模与大规模评测。
以第一或合作作者在 **MobiCom**、**EdgeSys (最佳论文)**、**SEC** 等会议发表系统方向工作; 工程侧长期用 **C/C++** 编写事件驱动的分布式后端与容错逻辑, 具备 **Triton GPU 算子开发**、**CUDA Green Context 算力分区**、**Verilog/FPGA 处理器实现**、**LLVM 编译优化**与 **Linux 内核构建**的完整链路经验, 覆盖从 RTL 到框架的各层抽象。

教育背景

- **爱丁堡大学 (The University of Edinburgh)** 英国爱丁堡
计算机科学研究型硕士, *ICSA*, 导师 *Mahesh K. Marina* 教授 2025.09 – 2026.11 (预计)
 - 硕士论文 *Flux-DT*: 面向可回收算力的弹性、抗抢占有状态运行时。
- **爱丁堡大学 (The University of Edinburgh)** 英国爱丁堡
计算机科学学士, **一等荣誉学位 (First Class Honours)**, 英国最高等级 2021.09 – 2025.05
 - 相关课程: 计算机体系结构与设计 (成绩 A)、机器学习系统 (成绩 A)、操作系统、计算机系统、计算机通信与网络。

专业技能

- **编程语言** C / C++ (主力, 事件驱动分布式后端)、Python、Verilog、Bash、Java。
- **体系结构与硬件** RISC-V 处理器 RTL 实现与微架构优化、流水线冒险与前递、Cache 与存储层次定量分析 (CPI / 带宽)、FPGA 开发与上板验证 (Vivado、PYNQ-Z2)、CUDA Green Context 与 SM 算力分区。
- **AI 系统** PyTorch、Triton GPU 算子开发与调优、分布式训练、GPU 集群调度与抢占容忍、加速器干扰刻画、性能建模与 profiling。
- **系统与工具** Linux 内核构建与内核模块、KVM 虚拟化、LLVM 编译优化与自动量化、Protobuf 与自研 RPC、epoll 事件驱动网络编程、Docker、Kubernetes、Azure / GCP、Git。

科研与项目经历

- **Weaver: Foundation Model Training over Shared AI Compute Infrastructure** 论文在投
研究助理——负责算力借用控制器评测与大规模训练实验 2024 年 – 2026 年
 - **算力借用控制器评测**: 评测决定 AI 训练负载可从延迟敏感租户处借用多少加速器算力的控制器, 本质是加速器资源的近实时分配问题; 多站点测试床上借用至多 **83%** 的空闲算力, 同时不损害同驻延迟敏感负载的性能。
 - **GPU 剖析与干扰刻画**: 通过 GPU profiling 与底层实验刻画训练负载与同驻延迟敏感负载之间的资源干扰, 并执行评测所需的大规模分布式基础模型训练。
- **Morphling: Emulator for Distributed Machine Learning at the Edge** EdgeSys 2026, 最佳论文奖
研究助理——C++ 后端、故障容错与 GPU 算力划分 2025 年 10 月 – 2026 年 3 月
 - **C++ 后端与通信层**: 基于 epoll 事件循环与 Protobuf 消息实现代理服务端 / 客户端与设备追踪模块 (约 50 次提交集中于 csrc/backend), 支撑单台 GPU 服务器模拟至多 1,800 台异构设备。
 - **故障容错与动态伸缩**: 实现设备故障检测与目标设备重选、分区重排 (排除故障设备)、运行期动态增删设备数量, 定位并修复设备故障引发的通信死锁。
 - **GPU 算力划分**: 基于 CUDA Green Context 的 per-GEMM SM 分区, 经 autograd hook 按执行 trace 驱动切换, 实现细粒度的 GPU 算力隔离与共享。
- **GPU 算子开发与调优 (Machine Learning Systems 课程项目, 成绩 A)** 爱丁堡大学
独立完成 2024 年
 - **Triton 算子实现**: 用 Triton 手写 L2、余弦、点积、曼哈顿四类距离算子, 并在其上实现 KNN、K-Means 与近似最近邻检索; 按 BLOCK_SIZE 做分块与循环切分、掩码处理边界、合并访存以降低带宽压力, 替换框架层的通用实现。
- **RISC-V 处理器设计与 FPGA 实现 (Computer Architecture and Design 课程项目, 成绩 A)** 爱丁堡大学
独立完成 2023 年
 - **RTL 开发与上板验证**: 用 Verilog 实现算术逻辑单元、寄存器堆等处理器部件并集成为可运行的 RISC-V 处理器,

经 Vivado 综合实现后下载至 PYNQ-Z2 FPGA 开发板实测验证，并向实验导师现场演示答辩。

- **微架构优化**：自行设计微架构增强方案提升处理器性能，按定量方法评估 CPI 与访存带宽收益；课程覆盖流水线冒险与互锁、分支预测、乱序执行、Cache 参数空间与一致性协议。

• **EmuRAN: Scalable and Cost-Effective Cloud-based RAN Emulation System** MobiCom 2026

研究助理——负责端到端评测与云上部署（论文有条件录用） 2024 年 - 2026 年

- **内核与虚拟化**：编译并部署自定义 Linux 内核模块与改版 KVM 模块以支持时间膨胀虚拟机，自动化完成实例创建、跨实例网状网络路由与 Kubernetes 集群组建。
- **规模与保真度评测**：在公有云 **130 个实例、6,400 个 CPU 核**上模拟超过 **10,000** 台设备，规模较既有软件方案高两个数量级；设计并执行保真度（对照真实硬件）与可扩展性评测。

• **Flux-DT: An Elastic, Preemption-Tolerant Runtime for Stateful Workloads on Spare Compute** 硕士学位论文

爱丁堡大学——独立作者 2025 年 9 月 - 至今

- **有状态负载的抢占容忍**：既有算力共享方案默认借用方是无状态、可随时丢弃的；本工作面向持有必须跨中断存活的状态的负载，构建运行时使其能跑在突发、可被回收的算力上，既不破坏高优先级租户的性能保证，也不损坏自身状态。
- **近实时控制策略**：设计并实现控制回路，在高优先级负载所要求的时间尺度上，以迁移、降精度、挂起与恢复等分级动作响应资源压力，而非单一的驱逐决策。
- **调度启发式与卸载顺序**：将任务放置建模为跨相互干扰单元的联合优化目标，设计贪心启发式决定哪些工作值得执行；同一排序在算力被回收时决定卸载顺序。

• **CoSenseAQ: LLVM Auto-Quantization from Sensor Specifications** 论文在投，第一作者

研究助理，ICSA，导师 Antonio Barbalace 博士 2024 年 4 月 - 2025 年 5 月

- **编译器优化**：开发基于 LLVM 的自动量化框架，利用编译器无法从源码恢复的传感器规格信息驱动 IR 级变换，在嵌入式目标上同时降低代码体积与执行时间；全程涉及底层 C/C++ 与交叉编译工具链工作。
- **真实硬件测量**：在 ARM Cortex-M0 与 Cortex-A53 平台上评测，量化功耗、性能与面积（PPA）收益。

论文发表

EmuRAN: Scalable and Cost-Effective Cloud-based RAN Emulation System MobiCom 2026（有条件录用）
Ujjwal Pawar, Andrew E. Ferguson, Yufeng Xia, Xenofon Foukas, Mahesh Marina, Bozidar Radunovic ——第三作者

Morphling: Emulator for Distributed Machine Learning at the Edge EdgeSys 2026
Leyang Xue, Yufeng Xia, Ismaeel Bashir, Eren Mendi, Jiaxun Yang, Myungjin Lee, Mahesh Marina ——第二作者·**最佳论文奖**

Wasp: Foundation Model Training System for the Edge SEC 2026
Leyang Xue, Yufeng Xia, Myungjin Lee, Mahesh Marina ——第二作者

CoSenseAQ: Compiler Optimizations using Sensor Technical Specifications with Automatic Quantization 论文在投
Yufeng Xia, Pei Mu, Antonio Barbalace ——第一作者

Weaver: Foundation Model Training over AI-RAN Compute Infrastructure 论文在投
Leyang Xue, Tianxin Wang, Xin Zhe Khooi, Jiaxun Yang, Dheeraj Mahendiran, Yufeng Xia, Mun Choon Chan, Myungjin Lee, Mahesh Marina ——合作作者

实习经历

- **森科技有限公司——后端开发实习生** 中国苏州，2023.06 - 2023.09
商业工程团队交付线上后端接口；主导优衣库配送平台由 JFinal 迁移至 Spring Boot，参与代码评审与发布测试。技术栈：Java、MySQL、Redis、Kafka。

荣誉、语言与其他

- **荣誉** EdgeSys 2026（与 ACM MobiSys 2026 同期举办）**最佳论文奖（Morphling）**；本科一等荣誉学位。
- **语言** 中文（母语）；英语（流利，雅思 7.0、GRE 336）。
- **学术服务** EuroSys 2026 学生志愿者（现场会务）。